

2026 年第十一届数维杯大学生数学建模挑战赛（春季赛）题目

（请先阅读“数维杯大学生数学建模挑战赛（春季赛）论文格式规范”）

B 题 智能办公场景下多源异构文件识别与治理优化

（一）问题背景

随着数字化办公的持续推进，企事业单位在日常运行中积累了格式交错、结构繁杂的大规模文件数据。这些文件在格式上涵盖 Word、PDF、Excel 等多种类型，在完整性上，既包含未经拆分的原始文件，也包含在后续流转、汇总与调用过程中被转化为仅含标题、正文片段、来源信息等字段的半结构化数据。同时，不同文件在形成背景、表达方式、结构层次与业务属性上差异显著，内在结构各具特点。在真实办公场景中，同一主题内容往往以不同文种、不同长度和不同结构形式反复出现，而后续新流入的数据通常仅包含部分文本片段或有限字段。在此情况下，传统依赖人工阅读、判断与归档的处理方式，普遍暴露出效率低下、判定标准不一、误分类风险高及后续检索利用困难等问题。

近年来，以 OpenClaw 为代表的智能办公平台逐步展现出文档处理、流程自动化和任务协同等方面的应用能力，推动文件治理模式从以人工操作为主，向信息提取、类别归属判断、异常识别及流程优化等智能化方向演进。这一转变对文件处理系统提出了更高要求：既能从完整历史文档中发现相对稳定的组织规律，也能在信息不完整的条件下完成主题迁移与类别归属判断。然而，文件治理并不止于类别归属判定。研究表明，在处理复杂、模糊或高风险文档时，完全依赖自动化或完全依赖人工的方案均存在局限，而合理引入人工复核环节，往往更贴合真实应用场景的需求，因此，对于业务影响较大、时效要求较强或归属判断置信度较低的文件，往往还需引入人工复核等机制。

基于上述背景，如何从历史真实文件中识别其内在组织规律并建立相对稳定的主题体系、如何在信息受限的新数据条件下保持类别归属判定的

有效性、以及如何在业务规则和资源约束条件下统筹优化文件处理与归档流程，成为智能办公场景中三个相互关联的关键议题。

（二）需要解决的问题

请利用“附件数据”中列出的数据集，回答以下问题：

问题一：数据集 1 提供了一批历史真实文件数据，包含多种格式。不同文件在内容完整程度、表达方式、文体结构和业务属性上存在差异。请对数据集 1 中的多源异构文件进行特征挖掘，提取能够反映文件内容及属性的关键信息，并基于提取结果对文件进行分类，同时归纳各类别所对应的主题。

问题二：数据集 2 和数据集 3 提供了一批后续流入的新数据，包括半结构化数据和真实文件数据。请根据问题 1 建立的分类体系，将数据集 2 和数据集 3 中的数据归入相应类别，并自主设计评价指标对模型的分类效果以及新数据归属判断的结果的合理性、可解释性和迁移适用性等方面进行综合量化评价。同时，对于同时具有多个类别特征或无法明确归入某一类别的数据，根据所构建的指标建立模型开展讨论，提出相应的识别思路与处理方式。

问题三：请结合问题 2 中对数据集 2 和数据集 3 的归类判断结果，从紧急程度、错分风险和复核必要性三个方面对于待处理文件进行高、中、低等级划分，并自主构建权重参数。其中，对于主题归属不明确、时效要求较高或涉及资金分配的文件，应在等级划分和权重设置中重点考虑。进一步综合考虑文件归档的准确性、时效性与经济成本，建立模型，判断各文件后续是否需要进行人工复核以及人工复核的优先顺序。并在数据集 4 提供的三种资源约束场景下比较不同场景下的处理结果差异，提出合理建议。

（三）名词定义解释

多源异构文件：指来源不同、格式不同、内容组织方式不同的一组文件数据。例如 Word、PDF、Excel、图片、文本等都可视为异构文件，来自不同场景的文件，则体现了多源特征。

真实文件数据：指在实际办公或业务运行中形成并保存下来的原始文件材料，其内容和结构未被预先整理为统一格式。

半结构化数据：指介于结构化数据和非结构化数据之间的数据形式。它通常包含若干固定字段，如标题、正文片段、来源信息、时间信息等，但内容本身并不具有完全统一的格式和严格的表结构。

（四）附件数据

数据集 1：历史真实文件数据

数据集 2：后续流入的半结构化记录数据

数据集 3：后续流入的匿名原始文件数据

数据集 4：业务规则与资源约束表

（五）参考文献

- [1] Kadhim A. I. Survey on supervised machine learning techniques for automatic text classification[J]. Artificial Intelligence Review, 2019, 52(3): 273-292.
- [2] Wang K., Ding Y., Han S. C. Graph neural networks for text classification: a survey[J]. Artificial Intelligence Review, 2024, 57: 190.
- [3] Tsirmpas D., Gkionis I., Papadopoulos G. T., et al. Neural natural language processing for long texts: A survey on classification and summarization[J]. Engineering Applications of Artificial Intelligence, 2024, 136: 108231.
- [4] Abdallah A., Eberharter D., Pfister Z., et al. A survey of recent approaches to form understanding in scanned documents[J]. Artificial Intelligence Review, 2024, 57: 342.
- [5] Ding Y., Han S. C., Lee J., et al. Deep learning based visually rich document content understanding: a survey[J]. Artificial Intelligence Review, 2026, 59: 114.
- [6] Kastrati Z., Imran A. S., Yayilgan S. Y. The impact of deep learning on document classification using semantically rich representations[J]. Information Processing & Management, 2019, 56(5): 1618-1632.
- [7] Oral B., Eryigit G., Emekligil E. Information extraction from text intensive and

visually rich banking documents[J]. Information Processing & Management, 2020, 57(6): 102423.

[8] Wu X., Xiao L., Sun Y., et al. A survey of human-in-the-loop for machine learning[J]. Future Generation Computer Systems, 2022, 135: 364-381.

[9] Mosqueira-Rey E., Hernández-Pereira E., Alonso-Ríos D., et al. Human-in-the-loop machine learning: a state of the art[J]. Artificial Intelligence Review, 2023, 56: 3005-3054..

赛题声明：本赛事所有赛题仅授权 2026 年第十一届数维杯数学建模挑战赛参赛（春季赛）队伍使用，任何组织及个人未经组委会书面授权：严禁用于校内竞赛，篡改、复制等侵权行为。