

2026 年数维杯 B 题赛题解析

一、题目整体分析

1.1 赛题背景与宏观定位

本题面向智能办公场景下的多源异构文件识别与治理优化问题。题目所给数据既包含历史真实文件，又包含后续流入的半结构化记录和匿名原始文件，文件格式、文本完整程度、结构层次和业务属性均不一致。因此，本题并不是单纯的文本分类题，而是一个异构数据统、表征、历史主题体系构建、新数据迁移归属、人工复核与资源调度优化的综合建模问题。

从建模角度看，问题一要求从数据集 1 中挖掘稳定的类别结构和主题规律；问题二要求将这种分类体系迁移到数据集 2 和数据集 3，并对归属结果的合理性、可解释性和迁移适用性进行量化评价；问题三进一步要求结合问题二的分类置信度和业务风险，在资源受限条件下判断哪些文件需要人工复核以及复核优先级。三问之间具有明显递进关系，前一问输出的类别、概率、主题标签和风险信息，是后一问评价和调度模型的重要输入。

1.2 核心矛盾分析

本题需要重点处理以下三个矛盾，这也是论文能否体现建模深度的关键。

（1）多源异构数据与统一特征空间之间的矛盾。历史文件可能来自 Word、PDF、Excel、图片或文本等不同载体，直接使用原始格式进行分类不可行，必须先进行统一解析、清洗和标准化编码，将异构文件转化为可计算的文本特征空间。

（2）历史完整文件与后续不完整数据之间的矛盾。数据集 1 相对完整，适合建立主题体系；而数据集 2、数据集 3 中存在标题、片段、来源信息等不完整内容，分类模型需要具备迁移能力，不能只依赖完整长文本。

（3）自动归档效率与人工复核安全性之间的矛盾。若全部交由人工处理，效率和成本较高；若完全自动归档，则对主题模糊、置信度低或涉及资金分配的文件存在错分风险。需要设计自动分类、风险评价、人工复核的人机协同机制。

1.3 建模逻辑架构

本题可采用分层闭环建模思路，将三个问题统一到一条技术路线中：

(1) 数据统一层：对多源文件进行格式解析、文本抽取、清洗规范化和元数据保留，得到标准化文本样本。

(2) 分类建类层：基于文本-单词异构图构建图神经网络分类模型，利用 BERT 表征和 GCN 聚合能力完成历史文件分类，并通过 BERTopic 或 c-TF-IDF 方法归纳每一类的主题标签。

(3) 迁移评价层：利用问题一形成的分类体系，对新流入数据进行类别归属判断，并设计归属合理性、模型可解释性、迁移适用性等指标评价分类结果。

(4) 治理优化层：根据紧急程度、错分风险和复核必要性构建文件复核优先级得分，并进一步建立多目标混合整数规划模型，在资源约束下给出人工复核决策与排序。

二、数据预处理与特征工程

在进入建模阶段前，需要先把多源异构文件统一转化为模型可调用的数据形式。该部分建议作为论文的共同基础模块，服务于问题一、问题二和问题三。

2.1 版面分析与文本提取

对于图像和扫描版 PDF，可采用 OCR 识别与版面分析相结合的方法，先识别标题、正文、表格、印章和签名等区域，再按照阅读顺序提取文字。对于倾斜、模糊或背景噪声较强的图片，可在 OCR 前进行二值化、去噪、旋转矫正和仿射变换处理。

对于原生 PDF 和 Word 文件，用 PDF 解析工具或 python-docx 等方式提取正文文本，同时保留标题层级、字号、加粗、表格结构和页码等信息，用于辅助判断文件类型和业务属性。

对于 Excel 或半结构化记录，用字段名、字段值的序列化方式展开，例如将一行记录转化为“[标题]：……；[来源]：……；[正文片段]：……”的文本序列，使表格字段与上下文之间形成可被语言模型理解的输入。

对于纯文本文件，则统一转换为 UTF-8 编码，并处理异常换行、不可见字符、重复标点和无意义乱码。

2.2 文本清洗与规范化

利用正则表达式删除连续特殊符号、页眉页脚、水印残留和重复空白；结合办公场景词典，对业务关键词、组织名称、金额、日期、编号和文件来源等信息进行规范化。

对于需要输入 BERT 或 SBERT 的文本，不宜过度分词或删除句法结构，以免损失上下文语义。最后进行标准化样本构建，将所有清洗后的文件统一封装为标准样本结构，既保留文本语义，又保留格式和业务属性信息，为后续图构建、主题归纳、迁移分类和风险判断提供统一输入。

三、各小题详细分析

3.1 问题一：历史多源异构文件分类与主题归纳

核心任务

问题一的目标是利用数据集 1 中的历史真实文件，挖掘能够反映文件内容和属性的关键信息，并在此基础上对文件进行分类，同时归纳各类别对应的主题。该问应重点体现三个方面：一是多源异构文件如何被统一表达；二是分类模型如何建立；三是每一类主题如何解释。

建模核心步骤

(1) 构建标准文本特征空间。对不同格式文件进行解析后，提取标题、正文、关键词、来源、时间、表格字段和版面结构等信息。对于长文本，可采用分段编码后池化的方式形成文档向量；对于短文本或片段型文本，可更多依赖标题、来源和关键词信息补足语义。

(2) 构建文本-单词异构图。设无向异构图为

$$G = (V, E), \quad V = V_d \cup V_w,$$

其中， V_d 为文档节点集合， V_w 为单词节点集合。图中既包含文档与单词之间的 TF-IDF 连接，也包含单词与单词之间的 PMI 共现连接。邻接矩阵A可定义为：

$$A_{ij} = \begin{cases} \text{PMI}(i, j), & i, j \in V_w, \text{PMI}(i, j) > 0, \\ \text{TFIDF}_{ij}, & i \in V_d, j \in V_w, \\ 1, & i = j, \\ 0, & \text{otherwise.} \end{cases}$$

其中 PMI 用于刻画词汇之间的全局共现强度，其计算公式为：

$$\text{PMI}(i, j) = \log \frac{p(i, j)}{p(i)p(j)} = \log \frac{n_w(i, j) \cdot N_w}{n_w(i) \cdot n_w(j)}.$$

这里， $n_w(i, j)$ 表示词i和词j在滑动窗口中共同出现的次数， $n_w(i)$ 表示包含词i的窗口数， N_w 表示滑动窗口总数。

(3) 初始化节点特征。对于文档节点，可使用预训练 BERT 模型提取 [CLS] 向量作为初始特征：

$$\mathbf{x}_i = \text{BERT}_{\text{CLS}}(\mathbf{d}_i), \quad i \in V_d.$$

对于单词节点，可使用词嵌入向量初始化，或采用零向量后通过图结构逐层更新。最终得到初始特征矩阵：

$$\mathbf{X} \in \mathbb{R}^{N \times d}, \quad N = N_d + N_w.$$

(4) 利用 GCN 聚合语义与共现信息。设度矩阵 $\mathbf{D}$ 满足

$$D_{ii} = \sum_j A_{ij},$$

则归一化邻接矩阵为：

$$\tilde{\mathbf{A}} = \mathbf{D}^{-\frac{1}{2}} \mathbf{A} \mathbf{D}^{-\frac{1}{2}}.$$

第 1 层图卷积更新公式为：

$$\mathbf{H}^{(l+1)} = \sigma(\tilde{\mathbf{A}} \mathbf{H}^{(l)} \mathbf{W}^{(l)}), \quad \mathbf{H}^{(0)} = \mathbf{X}.$$

经过两层 GCN 后，捕获文档、词汇、文档的二阶关联关系：

$$\mathbf{H}^{(2)} = \text{GCN}(\mathbf{X}, \mathbf{A}).$$

提取文档节点对应的表示 $\mathbf{H}_{\text{doc}}^{(2)}$ ，再通过 Softmax 输出类别概率：

$$\mathbf{Z} = \text{softmax}(\mathbf{H}_{\text{doc}}^{(2)} \mathbf{W}_o + \mathbf{b}_o).$$

部分样本具有人工标签，则用带掩码交叉熵损失训练模型：

$$\mathcal{L} = - \sum_{i \in Y_L} \sum_{c=1}^K Y_{ic} \ln Z_{ic}$$

(5) 基于 BERTopic 或 c-TF-IDF 归纳类别主题。分类完成后，可对每一类文档内部进行主题挖掘。先利用 SBERT 得到类别内文档向量，再使用 UMAP 降维和 HDBSCAN 聚类识别细分主题。为提取主题标签，可将同一主题下所有文档合并为一个“类文档”，并采用 c-TF-IDF 衡量词汇代表性：

$$W_{t,c} = \text{tf}_{t,c} \cdot \log\left(1 + \frac{A}{\text{tf}_t}\right).$$

其中， $tf_{t,c}$ 表示词 t 在主题 c 中的频率， tf_t 表示词 t 在所有主题中的总频率， A 表示每个主题的平均词汇量。若某个词在某一主题中高频出现而在其他主题中较少出现，则其 $W_{t,c}$ 较高，可作为该类主题标签的候选关键词。

结果输出建议

问题一的结果建议以类别编号、主题名称、关键词、代表文件、类别解释的形式展示。例如每一类给出前若干个高权重关键词、典型文件标题、类别内文档数量和简短主题描述。这样既能体现分类结果，又能增强主题归纳的可解释性。

3.2 问题二：新流入数据归属判断与综合评价

核心任务

问题二需要将问题一建立的分类体系迁移到数据集 2 和数据集 3，对半结构化记录和匿名原始文件进行归类，并设计评价指标衡量分类效果、归属合理性、可解释性和迁移适用性。同时，对于具有多个类别特征或无法明确归类的数据，需要建立异常识别和处理机制。

建模核心步骤

(1) 对新数据进行一致化预处理。数据集 2 为后续流入的半结构化记录，数据集 3 为匿名真实文件，两者均应按照问题一的数据处理流程统一转化为标准文本样本。半结构化数据重点保留标题、正文片段、来源和时间字段；匿名真实文件则重点补充 OCR、格式解析和版面结构特征。

(2) 进行类别迁移归属判断。将新数据输入问题一训练得到的分类模型，得到每个样本属于 K 个类别的概率分布：

$$P^{(i)} = [p_1^{(i)}, p_2^{(i)}, \dots, p_K^{(i)}], \quad \sum_{k=1}^K p_k^{(i)} = 1.$$

按概率从大到小排序后，取最大概率对应类别作为初步归属类别：

$$\hat{y}_i = \operatorname{argmax}_k p_k^{(i)}.$$

若 p_1 与 p_2 差距较大，说明模型对该样本归属较为确定；若二者接近，则说明样本可能同时具有多个类别特征，需要进一步讨论。

(3) 构建归属合理性得分 ARS 。仅使用最大概率 p_1 容易把勉强归属判定成确定归属，因此引入概率边距进行修正。设 p_1 为最高概率， p_2 为次高概率，归属合理性得分定义为：

$$ARS = \alpha p_1 + (1 - \alpha) \frac{p_1 - p_2}{p_1}, \quad 0 < \alpha < 1.$$

其中， p_1 表示绝对置信度， $(p_1 - p_2)/p_1$ 表示分类边界安全裕度。 ARS 越接近 1，说明该样本归属越清晰； ARS 较低时，说明样本存在跨类特征或归属不稳定。

(4) 构建模型可解释性指数 MII 。分类结果不仅要给出类别，还要说明模型依据了哪些关键词或语义片段。若模型注意力集中于少数核心业务词，则解释性较强；若注意力分布过于均匀，则解释性较弱。设样本有效 Token 数为 L ，注意力权重为 $A = [a_1, a_2, \dots, a_L]$ ，且 $\sum_i a_i = 1$ ，定义：

$$MII = 1 - \frac{-\sum_{i=1}^L a_i \log_2 a_i}{\log_2 L}.$$

当 MII 较大时，说明模型的注意力更加聚焦，能够给出较明确的关键词解释；当 MII 较小时，说明模型判断依据较分散，应降低自动归档信任度。

(5) 构建迁移适用性指标 TAI 。由于数据集 2 和数据集 3 可能与历史数据集 1 存在分布差异，可采用最大均值差异 MMD 衡量源域和目标域表征的一致性。设源域文本表征为 $X_s = \{x_1, \dots, x_n\}$ ，目标域文本表征为 $X_t = \{y_1, \dots, y_m\}$ ，核函数为 $k(\cdot, \cdot)$ ，则：

$$MMD^2(X_s, X_t) = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n k(x_i, x_j) + \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m k(y_i, y_j) - \frac{2}{nm} \sum_{i=1}^n \sum_{j=1}^m k(x_i, y_j).$$

为便于解释，可将其转化为正向指标：

$$TAI = \exp(-\gamma MMD^2(X_s, X_t)), \quad \gamma > 0.$$

TAI 越接近 1，说明新数据与历史数据分布越接近，分类体系的迁移适用性越强；若 TAI 较低，则需要在结论中说明存在分布偏移风险。

(6) 建立边界样本与异常样本识别逻辑。根据模型输出概率和信息熵，可将新数据划分为三种状态：

状态 A：清晰样本。若

$$p_1 \geq \theta_{\text{conf}}, \quad \text{ARS} \geq 0.8,$$

则认为样本类别归属清晰，可直接自动归档。

状态 B：多类别重叠样本。若

$$p_1 < \theta_{\text{conf}}, \quad p_1 - p_2 < \varepsilon_{\text{margin}},$$

说明模型在两个类别之间摇摆，文件可能同时具有多个类别特征，可设置联合标签，并进入人工复核池。

状态 C：未知或分布外样本。若最大概率较低，且预测概率分布的信息熵接近最大熵：

$$H(P) = - \sum_{k=1}^K p_k \log_2 p_k \approx \log_2 K,$$

则说明模型无法给出明确归属，可判定为异常样本或潜在新类别，交由专家研判。

结果输出建议

问题二应输出数据集 2 和数据集 3 每个样本的预测类别、最大置信度、次高类别、ARS、MII、TAI 或所在数据集迁移适用性，以及样本状态标记。对于状态 B 和状态 C 样本，应单独列出并解释其进入人工复核的原因。

3.3 问题三：文件人工复核优先级与资源约束调度优化

核心任务

问题三要求结合问题二的归类结果，从紧急程度、错分风险和复核必要性三个方面对待处理文件进行高、中、低等级划分，并在数据集 4 给出的三种资源约束场景下，判断哪些文件需要人工复核以及人工复核优先顺序。该问本质上是“风险评分+资源分配+多目标优化”问题。

建模核心步骤

(1) 定义三类核心评价指标。对于文件 i ，设紧急程度为 U_i ，错分风险为 R_i ，复核必要性为 N_i ，三者均归一化到 $[0,1]$ 。

紧急程度 U_i 可由文件的时效要求、截止时间、业务流程节点等信息转化得到，值越大表示越紧急。

错分风险 R_i 可由分类模型的不确定性反向推导，既可以采用最大概率补集，也可以采用归一化熵：

$$R_i = 1 - p_{\max}^{(i)},$$

或者表示成：

$$R_i = \frac{-\sum_{k=1}^K p_k^{(i)} \log p_k^{(i)}}{\log K}.$$

复核必要性 N_i 则根据业务规则赋值。例如主题归属不明确、包含合同/公章/签名、涉及资金分配、来源异常或文件完整性不足时，复核必要性应提高。

(2) 采用 AHP-熵权法确定综合权重。AHP 用于体现主观业务偏好，熵权法用于反映数据本身差异程度。设主观权重为：

$$w_s = [w_{s1}, w_{s2}, w_{s3}],$$

客观权重通过熵权法计算。对标准化指标矩阵 $X = (x_{ij})$ ，先计算比例：

$$z_{ij} = \frac{x_{ij}}{\sum_{i=1}^n x_{ij}}.$$

第 j 个指标的信息熵为：

$$e_j = -\frac{1}{\ln n} \sum_{i=1}^n z_{ij} \ln z_{ij}.$$

对应客观权重为：

$$w_{oj} = \frac{1 - e_j}{\sum_{r=1}^3 (1 - e_r)}.$$

最终采用乘法合成得到综合权重：

$$w_j = \frac{w_{sj} w_{oj}}{\sum_{r=1}^3 w_{sr} w_{or}}, \quad j = 1, 2, 3.$$

(3) 构建文件复核优先级得分。对于题目特别强调的主题归属不明确、时效要求较高或涉及资金分配的文件，引入特殊文件指示变量 $I_{\text{special}}^{(i)} \in \{0, 1\}$ 。若文件满足任意特殊规则，则 $I_{\text{special}}^{(i)} = 1$ 。综合得分可定义为：

$$\text{Score}_i = (w_U U_i + w_R R_i + w_N N_i) \left(1 + \mu I_{\text{special}}^{(i)} \right), \quad \mu > 0.$$

其中， μ 为特殊文件加权系数。该设计可以保证高风险、高时效或资金相关文件在排序中被优先考虑。

(4) 划分高、中、低复核等级。可采用分位数法或 K-Means 聚类法对 Score_i 进行等级划分。若采用分位数法，可设定：

$$\text{Level}_i = \begin{cases} \text{高}, & \text{Score}_i \geq Q_{70}, \\ \text{中}, & Q_{30} \leq \text{Score}_i < Q_{70}, \\ \text{低}, & \text{Score}_i < Q_{30}. \end{cases}$$

其中， Q_{70} 和 Q_{30} 分别表示综合得分的 70%和 30%分位点。实际写作中也可根据数据集 4 的业务规则设置固定阈值。

(5) 建立人工复核多目标优化模型。设文件集合为 $\mathcal{I} = \{1, 2, \dots, N\}$ ，复核人员集合为 $\mathcal{J} = \{1, 2, \dots, M\}$ 。定义决策变量：

$$x_{ij} = \begin{cases} 1, & \text{文件 } i \text{ 分配给人员 } j \text{ 复核}, \\ 0, & \text{否则}, \end{cases}$$

$$y_i = \begin{cases} 1, & \text{文件 } i \text{ 被人工复核}, \\ 0, & \text{文件 } i \text{ 自动归档或暂不复核}. \end{cases}$$

两类变量之间满足：

$$y_i = \sum_{j \in \mathcal{J}} x_{ij}, \quad \sum_{j \in \mathcal{J}} x_{ij} \leq 1.$$

模型需要同时考虑时效性、经济成本和未复核风险。最大完工时间目标为：

$$Z_1 = \max_{j \in \mathcal{J}} \sum_{i \in \mathcal{I}} t_{ij} x_{ij}$$

人工复核成本为：

$$Z_2 = \sum_{i \in \mathcal{I}} \sum_{j \in \mathcal{J}} c_j t_{ij} x_{ij}$$

未复核导致的错分惩罚为：

$$Z_3 = \sum_{i \in \mathcal{I}} (1 - y_i) R_i C_{\text{penalty}}$$

采用线性加权法得到综合目标函数：

$$\min F = a_1 Z_1^* + a_2 Z_2^* + a_3 Z_3^*, \quad a_1 + a_2 + a_3 = 1.$$

其中， Z_1^* 、 Z_2^* 和 Z_3^* 表示归一化后的目标值， α_1 、 α_2 和 α_3 表示不同场景下的决策偏好。

(6) 设置基础约束与场景约束。基础约束包括每个文件最多分配给一名复核人员，高等级文件必须复核：

$$y_i = 1, \quad \forall i \in H.$$

在时间受限场景下，应限制人员最大工作负载：

$$\sum_{i \in \mathcal{J}} t_{ij} x_{ij} \leq T_{\max}, \quad \forall j \in \mathcal{J}$$

在预算受限场景下，应限制总复核成本：

$$\sum_{i \in \mathcal{J}} \sum_{j \in \mathcal{J}} t_{ij} x_{ij} \leq B_{\max}$$

在专家人力受限场景下，设专家集合为 $\mathcal{J}_{\text{expert}}$ ，专家负荷上限为 $L_{\max}$ ，则：

$$\sum_{i \in \mathcal{J}} \sum_{j \in \mathcal{J}_{\text{expert}}} t_{ij} x_{ij} \leq L_{\max}$$

若某些特殊文件必须由专家复核，还可设置：

$$x_{ij} = 0, \quad \forall i \in S, j \notin \mathcal{J}_{\text{expert}}.$$

(7) 采用遗传算法求解。由于该问题属于带资源约束的组合优化问题，文件数量较多时精确求解成本较高，可采用遗传算法进行近似求解。将长度为 N 的整数序列作为染色体，基因 g_i 表示文件 i 的处理方式：

$$g_i \in \{0, 1, \dots, M\}.$$

其中， $g_i = 0$ 表示文件 i 不进入人工复核， $g_i = j$ 表示文件 i 分配给人员 j 。适应度函数可设置为：

$$\text{Fitness} = \frac{1}{F + \lambda P(x)}.$$

其中， $P(x)$ 为约束违反罚函数， λ 为罚系数。若方案违反预算、时间或专家资源约束，则罚函数增大，使该个体在进化过程中被淘汰。

三种资源约束场景的比较思路

时间受限场景下，模型应优先处理高紧急度、高错分风险的文件，必要时舍弃低风险文件的人工复核，以保证整体时效性。

预算受限场景下，模型应优先保留高等级文件的复核，同时在中等级文件中选择“风险降低收益较高、复核成本较低”的样本。

专家人力受限场景下，模型应将专家资源优先分配给主题不明确、涉及资金分配或存在较高业务风险的特殊文件，普通文件可由一般复核人员处理或自动归档。

四、写作建议与亮点挖掘

4.1 突出三问之间的闭环关系

论文写作时不要把三问割裂成三个独立模型，而应强调问题一提供类别体系和主题解释，问题二提供新数据分类结果、置信度和异常识别，问题三利用这些结果进行复核决策与资源调度。这样可以体现模型链条的完整性。

4.2 强化结果可解释性

这题涉及办公文件治理，单纯给出分类标签并不充分。建议在结果部分增加关键词贡献、主题词云、注意力热力图、类别概率柱状图、UMAP 聚类可视化等内容，说明模型为什么将某个文件归入某一类。对于被判为多类别或未知类别的样本，应给出具体原因，例如“第一、第二类别概率接近”“主题关键词同时覆盖两个类别”“文本片段过短导致语义不足”等。

4.3 强调人机协同治理价值

问题三是本题区别于普通文本分类题的重要部分。建议在论文中明确指出，模型不是追求完全自动化替代人工，而是通过置信度、错分风险和业务规则识别出最需要人工介入的文件，实现“高置信样本自动归档、边界样本人工复核、未知样本专家研判”的分层治理机制。

4.4 建议呈现的关键表格与图形

建议至少设置以下结果表和图：

（1）数据预处理统计表：展示不同格式文件数量、平均文本长度、缺失字段比例等。

（2）问题一分类结果表：展示类别编号、主题名称、关键词、代表文件和样本数量。

（3）问题二归属评价表：展示数据集2和数据集3中各样本的预测类别、置信度、ARS、MII 和状态标签。

（4）问题三复核优先级表：展示文件编号、紧急程度、错分风险、复核必要性、综合得分、等级和是否复核。

（5）资源约束场景对比表：展示三种场景下的复核文件数量、总成本、最大完工时间、未复核风险和高等级文件覆盖率。